Komunikácia s adaptívnym modelom prijímateľa: prehľad konceptuálneho rámca

krse

Abstrakt

Klasická Shannonova teória informácie chápe prijímateľa ako pasívny dekóder, ktorý rekonštruuje vyslanú správu s minimálnou distorziou. Reálny prijímateľ však nie je optimálny: má obmedzený výpočtový výkon, vlastný model sveta, cieľ rozhodovania a individuálnu históriu interakcií. Tento článok navrhuje konceptuálny rámec, ktorý tieto aspekty explicitne zahŕňa. Hlavnými komponentmi sú: (i) rozšírenie rate-distortion funkcie o model a cieľ prijímateľa, (ii) učenie parametrov prijímateľa zo spoločnej histórie komunikácie, (iii) pravdepodobnostný rozhodovací model, ktorý meratelnou funkciou vyjadruje *cenu adaptácie* a porovnáva ju s očakávaným ziskom, čím umožňuje racionálne rozhodnutie o tom, či je túto cenu vôbec vhodné akceptovať, a (iv) termodynamické limity takejto adaptácie. Ústrednou tézou je, že optimalizácia prenosu nie je zadarmo: každé zlepšenie efektivity vyžaduje výpočet, pamäť, čas alebo energiu, a niekedy táto cena prevýši hodnotu získanej informácie. Cieľom je pomenovať otvorené otázky a pripraviť terén pre formálne výsledky; článok nedokazuje nové vety, ale identifikuje miesta, kde by mohli vzniknúť.

1 Úvod

Shannonova rate-distortion teória [1, 2] stanovuje fundamentálnu medzu efektivity prenosu: zdroj X sa komprimuje do R bitov a dekóder rekonštruuje $\hat{X}$ s chybou $d(X, \hat{X}) \leq D$. Krivka $R(D)$ je minimálny rate pri danej distorzii a Shannon dokázal, že je dosiahnuteľná (s vhodne dlhým kódovým blokom) nezávisle od prijímateľa.

Wyner a Ziv [3] rozšírili teóriu pre prípad, keď prijímateľ disponuje vedľajšou informáciou S so známym spoločným rozdelením $P(X, S)$. Rate klesá na

$$R_{WZ}(D) \;=\; \min_{P(U|X)} [I(X;U) - I(S;U)]$$

s rekonštrukciou $\hat{X} = \kappa(U, S)$.

Obe formulácie však predpokladajú, že prijímateľ je optimálny dekóder s dokonalou znalosťou štatistík. V praxi to neplatí. Jazyk, dialóg ľudí a strojov, sieťová komunikácia s rôznymi koncovými uzlami, federované učenie, všetko sú systémy, kde prijímateľ je *agent* s vlastným modelom, cieľom a obmedzeniami. Tento článok zhrnuje rámec, ktorý tieto prvky zavádza ako prvotriedne premenné.

2 Model prijímateľa

Prijímateľa charakterizujeme trojicou (M, G, κ):

- M: *model sveta*, odhadované rozdelenie nad X, vo všeobecnosti odlišné od skutočného P_X.
- G: *cieľ*, úloha s akčným priestorom $\mathcal{A}$ a loss funkciou $\ell(a, X)$.
- $\kappa_M : \mathcal{I} \to \mathcal{A}$: *rozhodovacia funkcia* parametrizovaná modelom M, nie ľubovoľná.

Navrhovaná rate-distortion funkcia:

$$R_{M,G}(L) \;=\; \min_{f:\mathcal{X}\to\mathcal{I}} \mathbb{E}[|f(X)|] \quad \text{s.t.} \quad \mathbb{E}[\ell(\kappa_M(f(X)), X)] \le L. \tag{1}$$

Odlišnosti oproti R_{WZ}:

1. distorzia meraná *task-lossom* ℓ miesto $d(X, \hat{X})$,
2. κ je *fixovaná modelom* M, nie voľne optimalizovaná,
3. očakávanie pod skutočným P_X, ale κ používa *vnímaný* model M, takže mismatch je vlastná zložka straty.

Neformálna dekompozícia očakávanej straty:

$$\mathbb{E}[\ell] \;\approx\; \underbrace{L^\star(R)}_{\text{rate-limited}} \;+\; \underbrace{\Delta(M, P_X)}_{\text{model mismatch}} \;+\; \underbrace{\Delta(\kappa_M, \kappa^\star)}_{\text{bounded compute}} \;.$$

Druhý a tretí člen nie sú odstrániteľné zvyšovaním R, čo je zásadne nové oproti Shannonovi.

3 História ako zdroj adaptácie

Parametre (M, G, κ) vo všeobecnosti nepoznáme a v praxi sa líšia medzi prijímateľmi. Jediný reálne dostupný zdroj informácie o konkrétnom prijímateľovi je *história* spoločnej komunikácie. Analogicky s univerzálnym zdrojovým kódovaním [4, 5] platí:

$$R_T \;=\; R^\star \;+\; \frac{c(k)}{T}$$

kde $R^\star$ je optimálny rate pri plnej znalosti prijímateľa, T dĺžka histórie, k zložitosť modelu. Pre veľké T:

$$\lim_{T\to\infty} \frac{1}{T} \sum_{t=1}^{T} R_t \;=\; h(X, A), \tag{2}$$

kde $h(X, A)$ je *entropický rate* spoločného procesu zdroja a reakcií prijímateľa. Toto je neredukovateľná dolná hranica.

Komunikácia sa teda prirodzene delí na tri fázy:

1. *Cold phase*: univerzálny kód, zber histórie.
2. *Warm phase*: postupná adaptácia na odhadnutý (M, G, κ).
3. *Steady state*: $R_T \to R_{M,G}(L)$, penalty $c(k)/T$ mizne.

V prípade obojsmernej interakcie [6, 7] je konvergencia rýchlejšia, pretože každá výmena nesie dva signály (obsah + nepriamy signál o cieli).

Ak máme k dispozícii históriu *viacerých* prijímateľov, môžeme odhadnúť *populačný manifold* v priestore parametrov. Pre nového prijímateľa potom stačí lokalizácia niekoľkými pozorovaniami a adaptačná penalty klesá na $c(d)/T$, kde $d \ll k$ je vnútorná dimenzia manifoldu (hierarchický Bayes, meta-learning).

4 Rozhodovací rámec: kedy adaptovať

Centrálna téza tohto článku znie: optimalizácia prenosu nie je zadarmo. Adaptácia stojí čas $\tau(T)$, pamäť, energiu a výpočet. Preto potrebujeme *meratelnú funkciu*, ktorá vyjadrí cenu adaptácie a postaví ju proti očakávanému zisku, aby sme sa mohli racionálne rozhodnúť, či túto cenu vôbec akceptovať. Bez takejto funkcie sa optimalizácia stáva dogmou, pričom v niektorých prípadoch je jej cena vyššia než hodnota získanej informácie.

Definujeme očakávaný zisk a očakávaný náklad:

$$\text{Benefit} = N_{\text{future}} \cdot [R_{\text{univ}} - R_{\text{adapt}}(T)] \cdot c_{\text{bit}},$$

$$\text{Cost}(T) = C_{\text{comp}} \cdot \tau(T) + C_{\text{energy}} + C_{\text{mem}}.$$

Deterministické rozhodovanie:

$$\text{adaptuj} \iff \text{Benefit} > \text{Cost}.$$

Keďže všetky vstupné veličiny (gap, dĺžka vzťahu, τ) sú neisté a žiadni dvaja prijímatelia nie sú identickí, prirodzenejšia je pravdepodobnostná verzia. Definujme:

$$P_{\text{improve}}(k) \;=\; \Pr\big[\, G \cdot N \cdot c_{\text{bit}} > C_{\text{comp}} \cdot \tau \,\big|\, \text{obs}_{1:k} \,\big], \tag{3}$$

kde G je gap $H(X) - h(X, A)$, N očakávaný počet budúcich správ. Funkcia $P_{\text{improve}}(k) \in [0, 1]$ je *meratelný výstup*, ktorý priamo podkladá rozhodnutie:

$$\text{adaptuj} \iff P_{\text{improve}}(k) > \theta.$$

Prah θ vyjadruje toleranciu rizika a ochotu platiť neistú cenu.

Pri Gaussovskom priore na populáciu (G, N) má P_{improve} uzavretú formu cez distribučnú funkciu Φ, teda je *exaktne vyčísliteľná* zo štatistík histórie a populácie. Presnosť odhadu populačných parametrov rastie ako $1/\sqrt{N_{\text{pop}}}$.

Funkcia $P_{\text{improve}}(k)$ nevie odpovedať pre $k = 0$ bez populačného prioru, keďže rozhodovací model vždy vyžaduje buď individuálnu históriu, alebo amortizovanú populačnú skúsenosť. Samotný výpočet P_{improve} má tiež cenu, ktorá musí byť nižšia než priemerná úspora z rozhodnutí, ktoré generuje; inak sa rozhodovací model stáva ďalším problémom, ktorý potrebuje vlastné rozhodnutie (princíp *selektívnej adaptácie*).

5 Termodynamické limity

Každá adaptácia modelu zahŕňa operácie nad pamäťou. Landauerov princíp [8] kladie dolnú hranicu na energiu nevratnej zmeny bitu:

$$E_{\min} = kT \ln 2.$$

V praxi moderné systémy pracujú cca $10^{10}\times$ nad Landauerovou hranicou, takže termodynamická zložka je zanedbateľná. V limitoch (reverzibilné, kvantové systémy, vysoko hustá pamäť) sa stáva dominantnou.

Globálne: druhý termodynamický zákon implikuje, že každá lokálna redukcia informačnej entropie sa vykupuje väčším nárastom entropie okolia. Informačná efektivita nie je zadarmo ani v tom najzákladnejšom fyzikálnom zmysle, pretože sa vždy platí teplom odovzdaným do okolia.

6 Hranice modelu

Model je abstrakcia nad symbolovou a sémantickou vrstvou komunikácie; fyzikálnu vrstvu (analógové veličiny, modulácia, šum kanála) predpokladá za vyriešenú prostredníctvom klasického *channel coding theorem*. Pod pojmom „dáta“ rozumieme bity prenesené kanálom; informácia, znalosť a múdrosť vznikajú až u prijímateľa prostredníctvom interakcie dát s jeho modelom.

Úplná efektivita prenosu nie je dosiahnuteľná z piatich nezávislých dôvodov: (1) šum kanála, (2) neúplná znalosť prijímateľa, (3) konečný čas prenosu, (4) konečný čas adaptácie, (5) ireducibilná entropia $h(X, A)$ spoločného procesu. Rámec sa sústredí na druhý a štvrtý bod.

7 Otvorené otázky

- **Gap teorém**: existuje presná horná/dolná hranica na $R_{M,G}(L) - R_{WZ}(L)$ ako funkcia $\mathrm{KL}(P_X \| M)$?
- **Rate-distortion pre manifold prijímateľov**: aký je optimálny rate na reprezentáciu prijímateľa s danou kvantizačnou chybou? Táto otázka spája Shannonovu rate-distortion teóriu s manifold learningom a nonparametric Bayes.
- **Optimal stopping**: existuje uzavretá forma prahu $\theta^\star(\tau, N)$ pre pravdepodobnostné rozhodnutie (3)?
- **Task-aware entropický rate**: pre akú triedu cieľov G sa entropický rate $h(X, A)$ znižuje pod $h(X)$? Možno charakterizovať tieto triedy informačne-geometricky?
- **Ekvivalencia s information bottleneck** [9]: je kategorizácia prijímateľov ekvivalentná úlohe IB s task lossom ako relevanciou?

8 Záver

Prezentovaný rámec konsoliduje viaceré myšlienkové prúdy: rate-distortion s vedľajšou informáciou, univerzálne zdrojové kódovanie, semantickú komunikáciu [10], meta-learning a online adaptáciu. Žiaden z jednotlivých výsledkov nie je nový, nové je ich *integrované zarámovanie* s explicitným rozhodovacím modulom a termodynamickým pohľadom. Ústredným motívom je konštrukcia meratelnej funkcie pre cenu optimalizácie: bez nej sa adaptácia robí slepo, s ňou sa stáva racionálnym rozhodnutím, ktoré občas znie „neadaptuj“, lebo vo svete nie je nič zadarmo. Cieľom ďalšej práce je previesť otvorené otázky na formálne tvrdenia a dokázať aspoň jedno netriviálne.

Literatúra

[1] C. E. Shannon, *A mathematical theory of communication*, Bell System Technical Journal, vol. 27, 1948.

[2] C. E. Shannon, *Coding theorems for a discrete source with a fidelity criterion*, IRE Nat. Conv. Rec., 1959.

[3] A. D. Wyner, J. Ziv, *The rate-distortion function for source coding with side information at the decoder*, IEEE Trans. Inf. Theory, vol. 22, 1976.

[4] J. Rissanen, *Modeling by shortest data description*, Automatica, vol. 14, 1978.

[5] J. Ziv, A. Lempel, *A universal algorithm for sequential data compression*, IEEE Trans. Inf. Theory, vol. 23, 1977.

[6] A. H. Kaspi, *Two-way source coding with a fidelity criterion*, IEEE Trans. Inf. Theory, vol. 31, 1985.

[7] A. Orlitsky, *Worst-case interactive communication I: Two messages are almost optimal*, IEEE Trans. Inf. Theory, vol. 36, 1990.

[8] R. Landauer, *Irreversibility and heat generation in the computing process*, IBM J. Research and Development, vol. 5, 1961.

[9] N. Tishby, F. C. Pereira, W. Bialek, *The information bottleneck method*, Proc. 37th Allerton Conf., 1999.

[10] P. Popovski, O. Simeone, F. Boccardi, D. Gündüz, O. Sahin, *Semantic-effectiveness filtering and control for post-5G wireless connectivity*, Journal of the Indian Institute of Science, 2020; a následne literatúra o semantic communication, review 2022.